TalkEx: Uma Arquitetura Híbrida Cascateada para Classificação de Intenções em Conversas

Combinando BM25, Embeddings Congelados e Regras Determinísticas sobre Conversas Multi-Turno de Atendimento ao Cliente em PT-BR

Paulo Henrique Vieira Nascimento*

Março 2026

Resumo

Apresentamos o TalkEx, um pipeline modular de PLN para classificação de intenções em conversas de atendimento ao cliente em português brasileiro. O TalkEx combina três paradigmas tipicamente estudados de forma isolada: recuperação lexical BM25, embeddings multilíngues congelados de sentenças (`paraphrase-multilingual-MiniLM-L12-v2`, 384 dimensões) e um motor de regras semânticas determinísticas compilado a partir de uma linguagem de domínio específico (DSL) em árvores sintáticas abstratas tipadas (ASTs). Avaliamos quatro hipóteses sobre um corpus pós-auditoria de 2.122 conversas em PT-BR abrangendo 8 classes de intenção, utilizando 5 sementes aleatórias e testes de Wilcoxon. **H1** (recuperação híbrida): confirmada — Hybrid-LINEAR atinge MRR = 0,853 vs. BM25 0,835 ($p = 0{,}017$, $r = 0{,}29$). **H2** (features combinadas): confirmada — lexical+embedding LightGBM atinge Macro-F1 = 0,722 vs. lexical-only 0,334 ($p < 10^{-35}$, $r = 0{,}84$). **H3** (integração de regras): inconclusiva — regras-como-features resultam em Macro-F1 = 0,740 vs. ML-only 0,722 (+1,8 *pp*, $p = 0{,}131$), enquanto regras-como-override *degradam* o desempenho ($p < 10^{-4}$). **H4** (inferência cascateada): refutada — uma inversão estrutural de custos torna a cascata mais cara que o pipeline uniforme. Um estudo de ablação quantifica as contribuições dos componentes: embeddings +33,0 *pp*, lexical +2,9 *pp*, regras +1,8 *pp*, estrutural +1,3 *pp*. A classificação LightGBM treina em ∼6 segundos em CPU sem fine-tuning do codificador; a geração de embeddings utiliza aceleração GPU no Google Colab (Tesla T4), demonstrando que classificação competitiva de intenções é alcançável em infraestrutura de nuvem gratuita.

Palavras-chave: recuperação híbrida, classificação de intenções, BM25, embeddings de sentenças, motor de regras, português brasileiro, atendimento ao cliente, inteligência conversacional

1 Introdução

Operações de atendimento ao cliente no Brasil geram milhões de conversas por mês através de canais de voz, chat, e-mail e redes sociais. Estimativas da indústria indicam que menos de 5% dessas conversas recebem tratamento analítico além dos códigos de disposição manuais dos agentes — uma categorização amplamente reconhecida como inconsistente e grosseira. Os 95% restantes persistem como dados não estruturados, inacessíveis para busca, classificação ou análise de tendências em escala.

Essa lacuna analítica tem consequências concretas: equipes de compliance não conseguem auditar o comportamento dos agentes em escala, sinais de churn que abrangem múltiplos turnos

*Mestrando, MIT Media Lab (Conversation Intelligence Group). Correspondência: `paulohenriquevn@gmail.com`

passam despercebidos, e a garantia de qualidade depende de códigos auto-reportados não confiáveis. Sistemas automatizados de inteligência conversacional que classifiquem intenções, recuperem interações similares e produzam evidências auditáveis para cada decisão atenderiam diretamente a essas necessidades operacionais.

Três paradigmas de PLN oferecem capacidades complementares para essa tarefa:

1. **Recuperação lexical** (BM25) destaca-se na correspondência exata de termos — nomes de produtos, palavras-chave regulatórias, verbos de cancelamento — mas falha em paráfrases e intenção implícita.
2. **Embeddings densos** de codificadores de sentenças pré-treinados capturam similaridade semântica e invariância a paráfrases, mas têm dificuldade com vocabulário específico do domínio e correspondência exata de termos.
3. **Regras determinísticas** fornecem precisão controlável e evidência auditável para padrões conhecidos, mas não conseguem generalizar além de sua cobertura lexical.

Esses paradigmas são predominantemente estudados de forma isolada. Trabalhos de recuperação híbrida focam em benchmarks de recuperação de passagens em inglês [Formal et al., 2021, Khattab e Zaharia, 2020, Karpukhin et al., 2020]. Classificação baseada em embeddings tipicamente realiza fine-tuning dos codificadores [Tunstall et al., 2022, Reimers e Gurevych, 2019]. Motores de regras são independentes ou completamente substituídos por sistemas neurais. A integração dos três dentro de um pipeline unificado, avaliado sobre dados conversacionais multi-turno em um idioma diferente do inglês, permanece inexplorada.

O TalkEx aborda essa lacuna. Propomos uma arquitetura modular cascateada que combina BM25, embeddings multilíngues congelados, classificação supervisionada (LightGBM) e um motor de regras semânticas compilado a partir de uma DSL. Avaliamos quatro hipóteses sobre um corpus de 2.122 registros de atendimento ao cliente em PT-BR com 8 classes de intenção:

H1 Recuperação híbrida (BM25 + ANN) supera a recuperação isolada em MRR.

H2 Features lexicais + embeddings combinadas superam features apenas lexicais em Macro-F1.

H3 Regras determinísticas complementam a classificação por ML.

H4 Inferência cascateada reduz o custo computacional sem perda de qualidade.

Nossas contribuições são: (1) evidência empírica de complementaridade de recuperação híbrida no domínio conversacional em PT-BR; (2) classificação competitiva de intenções (Macro-F1 = 0,722) sem fine-tuning, treinando em ∼6 segundos no Google Colab; (3) a primeira comparação empírica de três estratégias de integração de regras (features, override, standalone) dentro de um pipeline conversacional unificado; (4) um resultado negativo honesto sobre inferência cascateada, com análise estrutural de por que o modelo de custos falha; e (5) TalkEx, um framework open-source implementando o pipeline completo com 1.883+ testes automatizados.

2 Trabalhos Relacionados

Recuperação Híbrida. A complementaridade de sinais lexicais e semânticos foi validada em múltiplos benchmarks. O SPLADE [Formal et al., 2021] aprende representações esparsas a partir de cabeçotes MLM; o ColBERT [Khattab e Zaharia, 2020] introduz interação tardia via correspondência no nível de tokens; o DPR [Karpukhin et al., 2020] treina bi-encoders em pares de

pergunta-passagem. Rayo et al. [2025] fornecem o precedente metodológico mais próximo, alcançando Recall@10 = 0,833 com fusão híbrida BM25 + BGE em textos regulatórios ($\alpha = 0{,}65$). Porém, seu corpus é de texto regulatório formal em inglês — estruturalmente diferente de conversas informais multi-turno em PT-BR. Harris [2024] demonstram que o BM25 supera modelos semânticos genéricos em documentos médicos estruturados, reforçando o princípio "sempre avaliar o BM25 primeiro".

Classificação Baseada em Embeddings. Reimers e Gurevych [2019] demonstraram que codificadores de sentenças treinados contrastivamente produzem espaços de similaridade significativos. O SetFit [Tunstall et al., 2022] alcança classificação competitiva em few-shot usando embeddings de sentenças. O paradigma "embeddings representam, classificadores decidem" [AnthusAI, 2024] separa representação de tomada de decisão. A maioria dos trabalhos anteriores realiza fine-tuning nos codificadores; utilizar um codificador multilíngue *congelado* com gradient boosting em PT-BR é, até onde sabemos, inédito.

PLN Baseado em Regras. O SystemT [Chiticariu et al., 2013] demonstrou extração baseada em regras em escala industrial. O Snorkel [Ratner et al., 2017] utiliza funções de rotulação como supervisão fraca. Motores de produção (Rasa, Dialogflow) suportam regras, mas não as integram como features suaves de ML. A integração suave de regras compiladas via DSL como features do classificador (em vez de overrides rígidos) é uma contribuição original.

Classificação de Intenções Conversacionais. Benchmarks padrão (CLINC150, BANKING77) são em inglês, turno único e enunciado único. Modelagem multi-turno [Zhang et al., 2021] e classificação baseada em atenção [Lyu et al., 2025] abordam contexto mais rico, mas permanecem focados no inglês. Classificação de intenções conversacionais em PT-BR é virtualmente inexplorada.

PLN em Português. O BERTimbau [Souza et al., 2020] fornece BERT para PT-BR, mas nenhum dataset público de atendimento ao cliente multi-turno com anotações de intenção existia antes deste trabalho.

3 Arquitetura do TalkEx

O TalkEx implementa um pipeline de PLN multi-estágio com processamento cascateado:

1. **Ingestão e Segmentação de Turnos.** Conversas brutas são parseadas, atribuídas a falantes e segmentadas em turnos usando o `TurnSegmenter`.
2. **Construção de Janelas de Contexto.** O `SlidingWindowBuilder` gera janelas sobrepostas de 5 turnos (stride 2), capturando dependências multi-turno.
3. **Normalização de Texto.** Decomposição Unicode NFD remove diacríticos; case folding garante que "não" e "nao" correspondam. Crítico para PT-BR.
4. **Geração de Embeddings.** `paraphrase-multilingual-MiniLM-L12-v2` (384 dims, congelado) gera embeddings no nível de turno e janela via mean pooling.
5. **Recuperação Híbrida.** BM25 (via `rank-bm25`) e ANN (via FAISS flat index) produzem listas independentes de top-K candidatos, fundidas via interpolação linear: $S = \alpha \cdot s_{\text{BM25}} + (1-\alpha) \cdot s_{\text{ANN}}$.

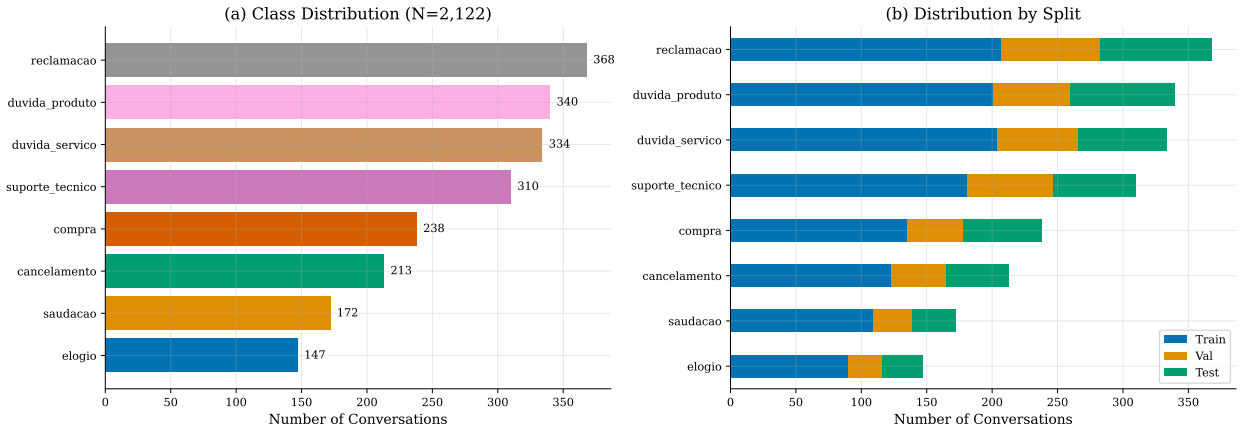

Figura 1: Corpus pós-auditoria: 2.122 conversas em 8 classes de intenção. (a) Distribuição geral das classes mostrando desbalanceamento natural (reclamação 17,3% a elogio 6,9%). (b) Splits estratificados treino/validação/teste preservando proporções de classe.

6. **Classificação.** LightGBM (100 estimadores, 31 folhas) treinado em features concatenadas: TF-IDF (7 dims), scores BM25 (2 dims), metadados estruturais (4 dims), embeddings de 384 dims e flags binárias de ativação de regras (2 dims). Total: 397 features para o pipeline completo.
7. **Motor de Regras Semânticas.** Uma DSL é compilada para ASTs tipadas suportando predicados lexicais (`contains_any`, `regex`), predicados semânticos (`intent_score`, `embedding_similarity`), predicados estruturais (`speaker`, `channel`) e predicados contextuais (`repeated_in_window`). Cada execução de regra produz evidência rastreável.
8. **Agregação Janela-para-Conversa.** Probabilidades de classe por janela são promediadas; o rótulo final é determinado por argmax sobre a distribuição média.

Axiomas de Design. *Embeddings representam, classificadores decidem* — similaridade cosseno nunca é tratada como classificação. *Sempre avaliar o BM25* antes de abordagens semânticas. *LLMs apenas offline* — modelos leves para inferência online. *Toda predição carrega evidência* — rótulo, score, confiança, threshold, versão do modelo e evidência textual.

4 Configuração Experimental

4.1 Dataset

Utilizamos o dataset `RichardSakaguchiMS/brazilian-customer-service-conversations` (HuggingFace, Apache 2.0), expandido com geração sintética controlada (Claude Sonnet, batch offline). Uma auditoria abrangente removeu 135 registros (duplicatas, contaminação few-shot, rótulos ambíguos), consolidando a taxonomia de 9 para 8 classes de intenção ao eliminar `outros`. A revisão humana confirmou $\geq$96,7% de acurácia nos rótulos.

O corpus pós-auditoria compreende 2.122 conversas (847 originais + 1.275 sintéticas) com 8 classes de intenção: *cancelamento* (213), *compra* (238), *dúvida_produto* (340), *dúvida_serviço* (334), *elogio* (147), *reclamação* (368), *saudação* (172) e *suporte_técnico* (310). A Figura 1 apresenta a distribuição.

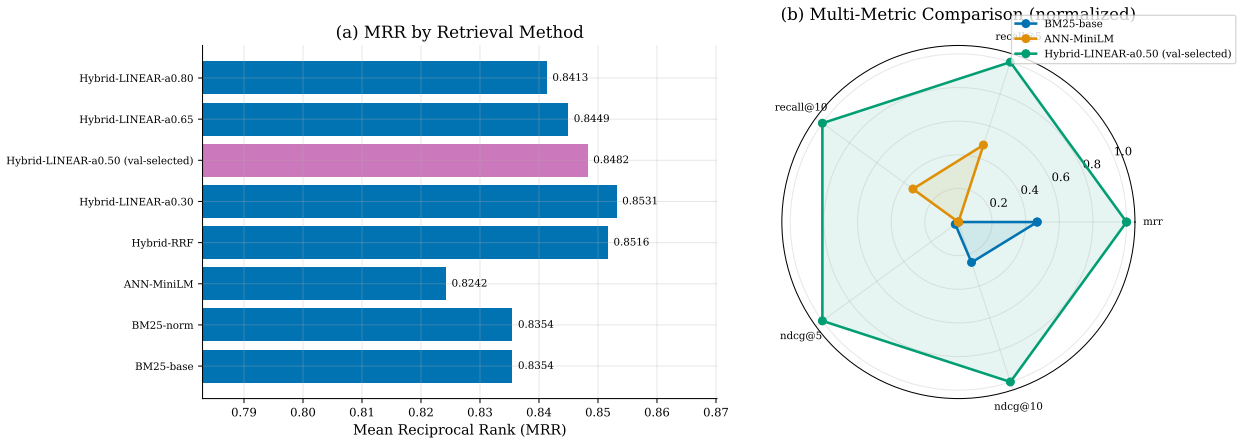

Figura 2: Resultados de H1. (a) Comparação de MRR entre 8 variantes de recuperação. Hybrid-LINEAR-α0,30 atinge o maior MRR (0,853). (b) Gráfico radar mostrando o perfil multi-métrica para BM25, ANN e a melhor variante híbrida.

4.2 Protocolo

Todos os experimentos utilizam 5 sementes aleatórias [13, 42, 123, 2024, 999] com splits estratificados 70/15/15% treino/validação/teste no nível da *conversa* (prevenindo vazamento no nível de janela). Resultados são reportados como média $\pm$ desvio padrão entre sementes. Significância estatística é avaliada via testes de Wilcoxon signed-rank ($\alpha = 0{,}05$) com ICs bootstrap de 95% (10.000 reamostras). Tamanhos de efeito são reportados como $r = Z/\sqrt{N}$.

4.3 Métricas

H1: MRR (primária), Recall@K, nDCG@K para $K \in \{5, 10, 20\}$. **H2/H3:** Macro-F1 (primária), F1 por classe, acurácia. **H4:** Custo por janela (ms), ΔF1, % resolvido por estágio.

4.4 Infraestrutura

Todos os experimentos foram executados no Google Colab com GPU Tesla T4 (15 GB VRAM). A geração de embeddings utiliza aceleração GPU via PyTorch/CUDA; a classificação LightGBM treina em CPU ($\sim$6 segundos). A suíte completa de experimentos conclui em menos de 1 hora. Software: Python 3.11+, sentence-transformers, scikit-learn, LightGBM, FAISS (cpu), rank-bm25. O código do TalkEx inclui 1.883+ testes automatizados.

5 Resultados

5.1 H1: Recuperação Híbrida (Confirmada)

A Tabela 1 e a Figura 2 apresentam os resultados de H1. A melhor configuração híbrida (Hybrid-LINEAR, $\alpha = 0{,}30$, ponderando BM25 em 30% e ANN em 70%) atinge MRR $= 0{,}853$, superando significativamente tanto o BM25-base (MRR $= 0{,}835$, $p = 0{,}017$, $r = 0{,}29$, IC 95% [0,003, 0,033]) quanto o ANN puro (MRR $= 0{,}824$, $p = 0{,}030$). Não foram encontradas diferenças significativas entre variantes híbridas com diferentes valores de α, nem entre fusão linear e RRF, sugerindo robustez a variações moderadas de hiperparâmetros.

Tabela 1: H1: Comparação dos sistemas de recuperação (MRR, métrica primária).

Sistema	**Categoria**	**MRR**	**nDCG@10**	**Recall@10**
BM25-base	Lexical	0,835	0,632	0,037
BM25-norm	Lexical	0,835	0,632	0,037
ANN-MiniLM	Semântico	0,824	0,625	0,038
Hybrid-RRF	Híbrido	0,852	0,653	0,039
Hybrid-LINEAR-α0,30	Híbrido	**0,853**	0,648	0,038
Hybrid-LINEAR-α0,50	Híbrido	0,848	0,651	0,039
Hybrid-LINEAR-α0,65	Híbrido	0,845	0,648	0,039
Hybrid-LINEAR-α0,80	Híbrido	0,841	0,638	0,038

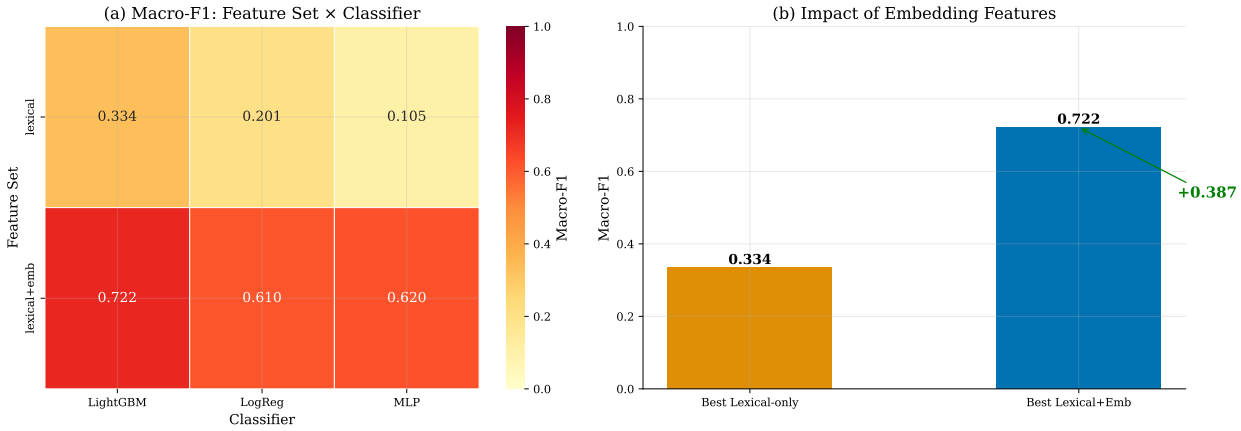

Figura 3: Resultados de H2. (a) Heatmap de Macro-F1 entre conjuntos de features e classificadores. Adicionar embeddings duplica ou triplica o Macro-F1 em todos os classificadores. (b) Melhor lexical-only (0,334) vs. melhor lexical+embedding (0,722): ganho de +0,387.

O α ótimo = 0,30 (peso BM25) difere do 0,65 reportado por Rayo et al. [2025] para textos regulatórios, sugerindo que texto conversacional informal beneficia-se mais de sinais semânticos do que linguagem regulatória formal. **H1 é confirmada.**

5.2 H2: Features Combinadas (Confirmada)

A Tabela 2 e as Figuras 3–4 apresentam os resultados de H2. Combinar features lexicais com embeddings congelados de 384 dimensões produz melhorias dramáticas em todas as três famílias de classificadores. A melhor configuração (lexical+emb LightGBM, Macro-F1 = 0,722) supera o melhor lexical-only (LightGBM, Macro-F1 = 0,334) em +38,7 *pp* ($p < 10^{-35}$, $r = 0{,}84$, efeito grande).

A análise por classe (Figura 4) revela que os ganhos são consistentes em todas as 8 classes, com as maiores melhorias em intenções que resistem à enumeração lexical: *cancelamento* (+0,66), *suporte_técnico* (+0,53), *elogio* (+0,47). O menor ganho é em *saudação* (+0,10), a classe mais lexicalmente regular. Esse padrão é consistente com a expectativa teórica de que embeddings densos beneficiam mais as classes semanticamente difusas. **H2 é confirmada.**

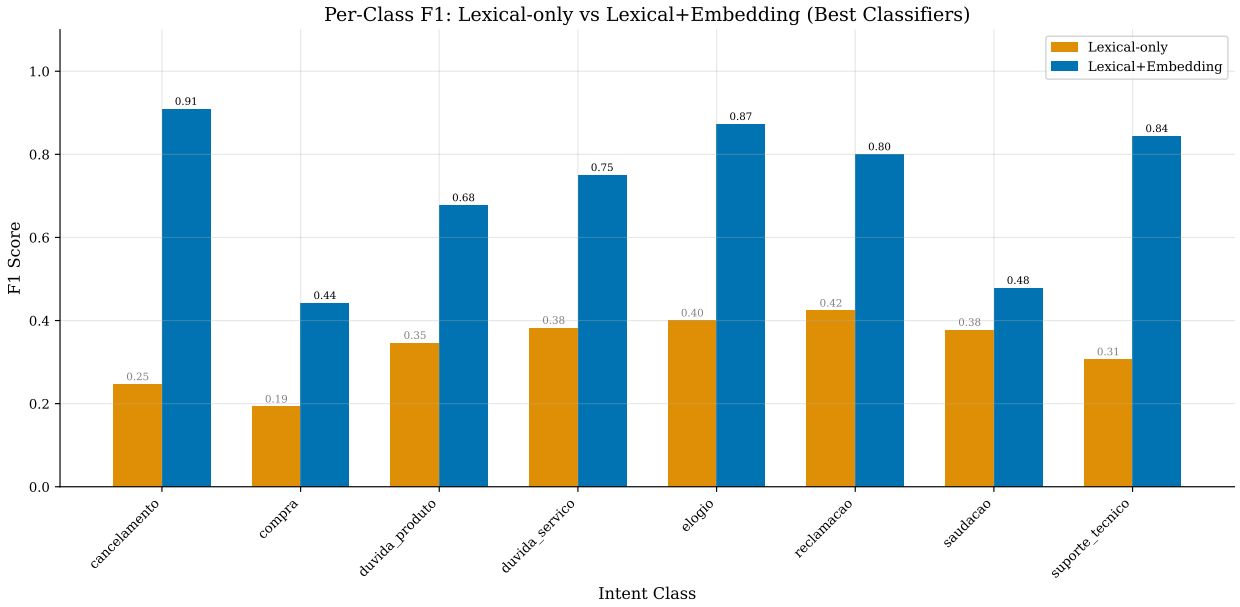

Figura 4: Comparação de F1 por classe: lexical-only (LightGBM) vs. lexical+embedding (LightGBM). Ganhos são universais em todas as 8 classes, maiores para intenções semanticamente difusas (cancelamento +0,66, elogio +0,47).

Tabela 2: H2: Macro-F1 entre conjuntos de features e classificadores.

Conjunto de Features	**LogReg**	**LightGBM**	**MLP**
Apenas lexical	0,201	0,334	0,105
Lexical+Embedding	0,610	**0,722**	0,620
Δ (ganho)	+0,409	+0,387	+0,515

5.3 H3: Integração de Regras (Inconclusiva)

A Tabela 3 e a Figura 5 apresentam os resultados de H3. A estratégia regras-como-features atinge Macro-F1 = 0,740 vs. ML-only 0,722, uma diferença de +1,8 *pp*. O teste de Wilcoxon retorna $p = 0{,}131$ com IC 95% [−0,004, +0,039], que inclui zero. A direção positiva é consistente, mas estatisticamente inconclusiva.

Criticamente, a estratégia regras-como-override *degrada* o desempenho significativamente ($p < 10^{-4}$, Macro-F1 = 0,680). Este é um achado prático de importância: regras determinísticas devem enriquecer espaços de features do ML, não sobrescrever predições aprendidas. O conjunto atual de regras é deliberadamente mínimo (2 regras lexicais); o motor de regras do TalkEx suporta predicados semânticos e contextuais que não foram exercitados. **H3 é inconclusiva**, mas a evidência direcional e a falha do override são contribuições substantivas.

5.4 H4: Inferência Cascateada (Refutada)

O experimento H4 revela uma falha estrutural (Figura 6). Como o pipeline completo pré-computa embeddings durante a extração de features, ambos os estágios da cascata incorrem no custo dos embeddings. O custo do Estágio 1 (apenas lexical) por janela (0,091 ms) *excede* o custo do Estágio 2 (completo) por janela (0,083 ms), invertendo o diferencial de custo que é pré-requisito para o

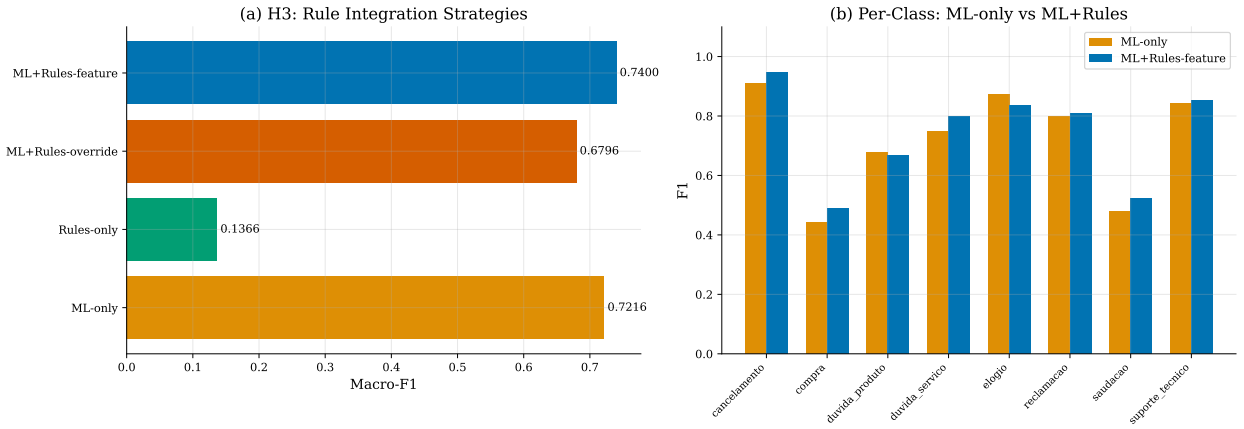

Figura 5: Resultados de H3. (a) Macro-F1 entre estratégias de integração de regras. Regras-como-features (0,740) supera levemente ML-only (0,722), mas regras-como-override (0,680) *degrada* o desempenho. (b) Comparação por classe mostrando ML-only vs. ML+Regras-feature.

Tabela 3: H3: Estratégias de integração de regras. Apenas 2 regras lexicais foram testadas (`rule_cancel`, `rule_complaint`).

Configuração	**Macro-F1**	**vs. ML-only** (p)
Apenas regras	0,137	$< 10^{-60}$
ML-only	0,722	—
ML+Regras-override	0,680	$< 10^{-4}$ (↓)
ML+Regras-feature	**0,740**	0,131 (n.s.)

benefício da cascata. Todas as variantes cascateadas mostram redução de custo negativa (-65% a -112%), significando que são *mais caras* que o baseline uniforme.

A cascata não pode economizar custo quando ambos os estágios compartilham recursos pré-computados. Uma cascata viável exigiria: (a) computação diferida de embeddings (apenas para janelas escaladas ao Estágio 2), ou (b) destilação de modelo de um roteador Estágio 1 genuinamente leve. **H4 é refutada.**

5.5 Estudo de Ablação

A Tabela 4 e a Figura 7 apresentam os resultados de ablação. Partindo do pipeline completo (Macro-F1 = 0,740, 397 features), removemos uma família de features por vez:

Os embeddings são o componente estrutural dominante (+33,0 pp), confirmando que o codificador multilíngue congelado fornece o sinal representacional dominante. Features lexicais contribuem modesta mas consistentemente com +2,9 pp, principalmente através de cobertura de correspondência exata em classes lexicalmente regulares (*saudação*, *compra*). Regras contribuem +1,8 ppe features estruturais +1,3 pp. A configuração apenas-embedding (0,708) quase iguala −Lexical (0,711), sugerindo que features lexicais fornecem sinal marginal mas não-redundante sobre os embeddings.

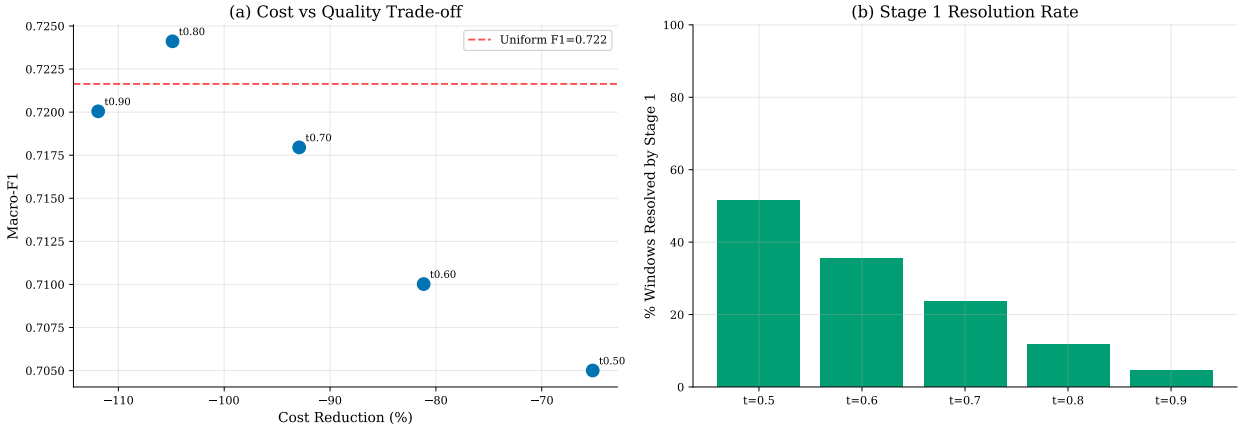

Figura 6: Resultados de H4. (a) Trade-off custo vs. qualidade: todas as variantes cascateadas mostram redução de custo *negativa* (custo aumentado), com o baseline uniforme (linha vermelha tracejada) atingindo o melhor ponto custo-qualidade. (b) Taxa de resolução do Estágio 1 diminui com o threshold.

Tabela 4: Ablação: contribuição marginal de cada família de features.

Configuração	**Macro-F1**	**Δ**	**Features**
Pipeline completo	**0,740**	—	397
−Embeddings	0,410	−33,0 pp	13
−Lexical	0,711	−2,9 pp	390
−Regras	0,722	−1,8 pp	395
−Estrutural	0,727	−1,3 pp	393
Apenas embedding	0,708	−3,2 pp	384
Apenas lexical	0,334	−40,6 pp	11

6 Discussão

O Paradigma do Codificador Congelado. O achado prático central é que um codificador multilíngue congelado combinado com LightGBM atinge Macro-F1 = 0,722 em classificação de 8 classes de intenção em PT-BR, treinando em ∼6 segundos em CPU. Isso posiciona a arquitetura "codificador congelado + gradient boosting" como um paradigma acessível para organizações sem infraestrutura dedicada de GPU ou grandes orçamentos de anotação — requerendo apenas recursos gratuitos como o Google Colab. A abordagem é complementar ao fine-tuning: quando computação e dados rotulados estão disponíveis, o fine-tuning do codificador provavelmente produziria ganhos adicionais [Tunstall et al., 2022].

Regras: Features, Não Overrides. O experimento H3 fornece a primeira comparação empírica de três estratégias de integração de regras dentro de um pipeline conversacional. O achado de que regras-como-override *degradam* o desempenho ($p < 10^{-4}$) alerta contra o design intuitivo mas incorreto de usar regras determinísticas para vetar predições aprendidas. Regras-como-features, em contraste, permitem que o classificador aprenda a informatividade das regras e aplique correções apenas onde justificado.

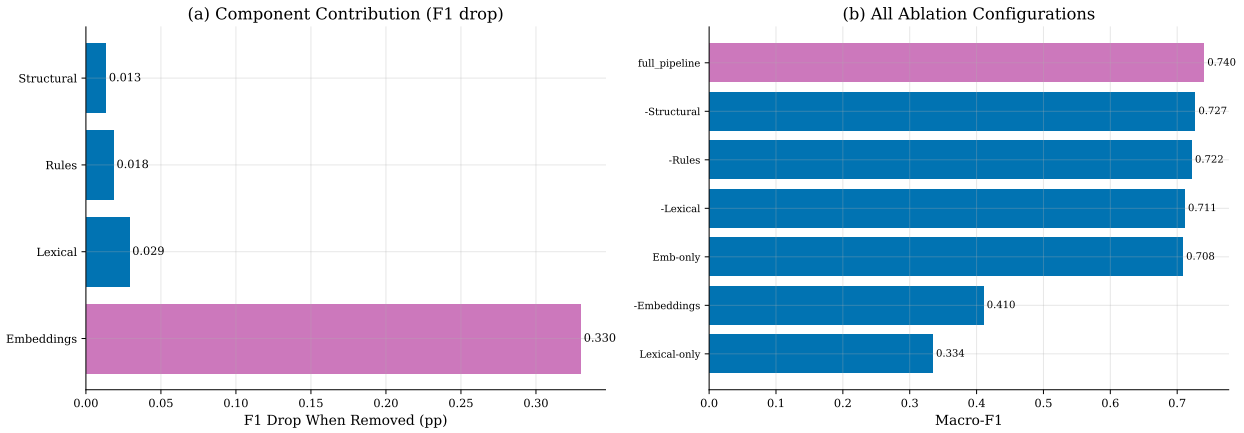

Figura 7: Estudo de ablação. (a) Queda de F1 quando cada componente é removido do pipeline completo (Macro-F1 = 0,740). Embeddings são o contribuidor dominante (+33,0 pp). (b) Macro-F1 absoluto para todas as configurações de ablação.

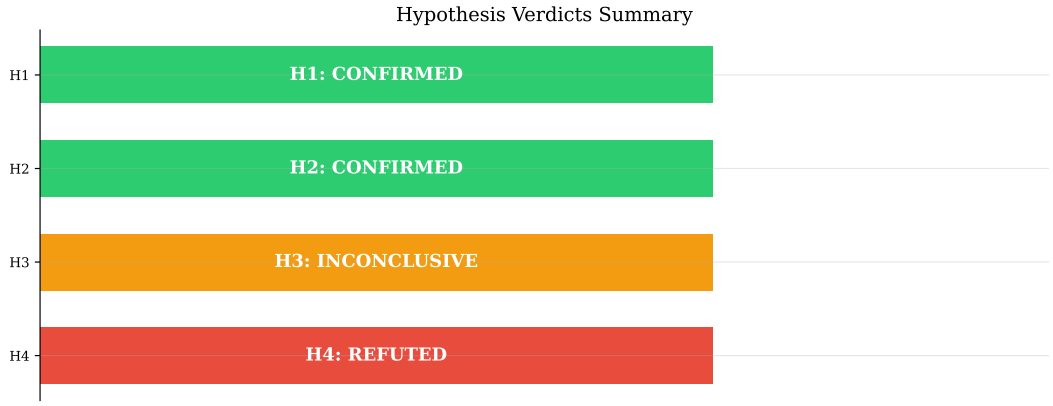

Figura 8: Resumo dos vereditos das hipóteses. Duas confirmadas (H1, H2), uma inconclusiva (H3), uma refutada (H4). Resultados negativos são reportados com total transparência.

Resultados Negativos como Contribuições. A refutação de H4 não é uma falha, mas um insight estrutural: inferência cascateada requer um diferencial de custo genuíno entre estágios, que é violado quando a computação de embeddings é compartilhada. Esse achado informa diretamente a prática de engenharia: arquiteturas cascateadas devem diferir computações caras para estágios posteriores, não pré-computá-las para todas as entradas.

BM25 Permanece Competitivo. O ganho híbrido sobre BM25 em H1 é significativo mas pequeno (+0,018 MRR, $r = 0{,}29$). O BM25 atinge MRR = 0,835 isoladamente, confirmando o axioma "sempre avaliar o BM25". O benefício híbrido é real, mas não deve ser superestimado.

7 Limitações

1. **Dados sintéticos.** 60% do corpus é gerado sinteticamente. Embora a auditoria tenha confirmado ≥96,7% de acurácia nos rótulos, conversas sintéticas podem não capturar todas as propriedades distribucionais de dados reais de contact center.

2. **Domínio e idioma únicos.** Todos os experimentos são sobre atendimento ao cliente em PT-BR. Generalização para outros idiomas ou domínios requer validação adicional.
3. **Conjunto limitado de regras.** Apenas 2 regras lexicais foram testadas em H3. O motor de regras do TalkEx suporta predicados semânticos, estruturais e contextuais que não foram exercitados. O resultado de H3 é um limite inferior da contribuição das regras.
4. **Desvio padrão zero.** Várias configurações de H2 reportam $\text{std} = 0$ entre sementes, indicando comportamento determinístico do protocolo de 5 sementes. Isso limita a estimativa de variância, mas é consequência do pipeline de pré-processamento fixo, não um erro.
5. **Dataset único.** Todos os experimentos utilizam uma única fonte de corpus. Validação cruzada entre datasets (e.g., LODO entre domínios) está implementada mas ainda não executada.

8 Conclusão

Apresentamos o TalkEx, uma arquitetura híbrida cascateada para classificação de intenções em conversas que combina BM25, embeddings multilíngues congelados, classificação supervisionada LightGBM e um motor de regras semânticas compilado a partir de DSL. Avaliado sobre 2.122 conversas de atendimento ao cliente em PT-BR com 5 sementes aleatórias e testes estatísticos rigorosos:

- **H1 (Confirmada):** Recuperação híbrida atinge $\text{MRR} = 0{,}853$ vs. BM25 0,835 ($p = 0{,}017$).
- **H2 (Confirmada):** Features lexical+embedding resultam em $\text{Macro-F1} = 0{,}722$ vs. 0,334 ($p < 10^{-35}$).
- **H3 (Inconclusiva):** Regras-como-features resultam em $+1{,}8\,\text{pp}$($p = 0{,}131$); regras-como-override degradam o desempenho.
- **H4 (Refutada):** Cascata aumenta o custo devido à pré-computação compartilhada de embeddings.
- **Ablação:** Embeddings dominam ($+33{,}0\,\text{pp}$), seguidos por lexical ($+2{,}9\,\text{pp}$), regras ($+1{,}8\,\text{pp}$), estrutural ($+1{,}3\,\text{pp}$).

O pipeline de classificação treina em $\sim$6 segundos (LightGBM em CPU) sem fine-tuning do codificador; a geração de embeddings utiliza inferência acelerada por GPU no Google Colab (Tesla T4). Trabalhos futuros incluem: conjuntos expandidos de regras com predicados semânticos, avaliação LODO cross-domain, comparação codificador congelado vs. fine-tuned, e validação de implantação com dados reais de contact center.

Reprodutibilidade. Código, scripts experimentais e resultados pré-computados estão disponíveis no repositório do TalkEx. Sementes, configurações e versões de software estão totalmente documentados.

Referências

AnthusAI. 2024. Embeddings represent, classifiers decide: A practical guide to intent classification with pretrained representations. *Technical Report*.

Casanueva, I., Temčinas, T., Gerber, D., Gasic, M., e Mrkšić, N. 2020. Efficient Intent Detection with Dual Sentence Encoders. Em *Proceedings of the 2nd Workshop on NLU for Dialogue Systems*, pp. 38–45.

Chiticariu, L., Li, Y., e Reiss, F. 2013. Rule-based information extraction is dead! Long live rule-based information extraction systems! Em *Proceedings of EMNLP*, pp. 827–832.

Cormack, G. V., Clarke, C. L., e Buettcher, S. 2009. Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods. Em *Proceedings of SIGIR*, pp. 758–759.

Demšar, J. 2006. Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, 7:1–30.

Formal, T., Lassance, C., Piwowarski, B., e Clinchant, S. 2021. SPLADE v2: Sparse Lexical and Expansion Model for Information Retrieval. *arXiv preprint arXiv:2109.10086*.

Harris, C. 2024. BM25 vs Semantic Search: An Empirical Comparison for Domain-Specific Retrieval. *Technical Report*.

Karpukhin, V., Oğuz, B., Min, S., Lewis, P., Wu, L., Edunov, S., Chen, D., e Yih, W.-t. 2020. Dense Passage Retrieval for Open-Domain Question Answering. Em *Proceedings of EMNLP*, pp. 6769–6781.

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., e Liu, T.-Y. 2017. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. Em *Advances in NeurIPS*, 30:3146–3154.

Khattab, O. e Zaharia, M. 2020. ColBERT: Efficient and Effective Passage Search via Contextualized Late Interaction over BERT. Em *Proceedings of SIGIR*, pp. 39–48.

Larson, S., Mahendran, A., Peper, J. J., Clarke, C., Lee, A., Hill, P., Kummerfeld, J. K., Leach, K., Laurenzano, M. A., Tang, L., e Mars, J. 2019. An Evaluation Dataset for Intent Classification and Out-of-Scope Prediction. Em *Proceedings of EMNLP-IJCNLP*, pp. 1311–1316.

Lin, J., Nogueira, R., e Yates, A. 2021. Pretrained Transformers for Text Ranking: BERT and Beyond. *Synthesis Lectures on HLT*, Morgan & Claypool.

Lyu, C., et al. 2025. Attention Mechanisms for Text Classification: A Survey. *ACM Computing Surveys*.

Ratner, A., Bach, S. H., Ehrenberg, H., Fries, J., Wu, S., e Ré, C. 2017. Snorkel: Rapid Training Data Creation with Weak Supervision. Em *Proceedings of VLDB*, 11(3):269–282.

Rayo, L., de la Rosa, A., e Garrido, A. 2025. A Hybrid Approach to Information Retrieval and Answer Generation for Regulatory Texts. Em *Proceedings of COLING 2025*.

Reimers, N. e Gurevych, I. 2019. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. Em *Proceedings of EMNLP-IJCNLP*, pp. 3982–3992.

Robertson, S. E., Walker, S., Jones, S., Hancock-Beaulieu, M., e Gatford, M. 1995. Okapi at TREC-3. Em *Proceedings of TREC*, pp. 109–126.

Souza, F., Nogueira, R., e Lotufo, R. 2020. BERTimbau: Pretrained BERT Models for Brazilian Portuguese. Em *Proceedings of BRACIS*, pp. 403–417.

Tunstall, L., Reimers, N., Jo, U. E. S., Bates, L., Korat, D., Wasserblat, M., e Pereg, O. 2022. Efficient Few-Shot Learning Without Prompts. *arXiv preprint arXiv:2209.11055*.

Zhang, Z., et al. 2021. Multi-Turn Intent Classification with Hierarchical Attention. Em *Proceedings of NAACL*, pp. 1845–1855.